



Asignación de características musicales para ambientación comercial

Autor:

Ing. Carlos Alberto Rivas Araque

Director:

Ing. Esp. Martín Moreyra (GatekeeperX)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 26 de agosto de 2025 y el 14 de octubre de 2025.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar.	5
2. Identificación y análisis de los interesados	6
3. Propósito del proyecto	7
4. Alcance del proyecto	7
5. Supuestos del proyecto.	8
6. Product Backlog	9
7. Criterios de aceptación de historias de usuario	11
8. Fases de CRISP-DM	12
9. Desglose del trabajo en tareas	13
10. Planificación de Sprints	15
11. Diagrama de Gantt (sprints)	17
12. Normativa y cumplimiento de datos (gobernanza)	17
13. Gestión de riesgos	18
14. Sprint Review	19
15. Sprint Retrospective	20

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	26 de agosto de 2025
1	Se completa hasta el punto 5 inclusive	9 de septiembre de 2025

Acta de constitución del proyecto

Buenos Aires, 26 de agosto de 2025

Por medio de la presente se acuerda con el Ing. Carlos Alberto Rivas Araque que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Asignación de características musicales para ambientación comercial” y consistirá en la implementación de un sistema de generación de características musicales a partir de canciones en el contexto de una aplicación de ambientación musical. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo estimado de 18750 dólares estadounidenses, con fecha de inicio el 26 de agosto de 2025 y fecha de presentación pública en junio de 2026.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Carolina Arbelaez
Plusyc Live SAS

Ing. Esp. Martín Moreyra
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El proyecto se hace para la empresa Plusyc Live SAS, dedicada a la creación de experiencias musicales personalizadas para locales comerciales a través de una aplicación móvil. La aplicación utiliza un *pool* de canciones propio, y un *backend* que crea listas de reproducción. Las listas se generan gracias a características musicales, tales como el género, ánimo, energía y tempo de cada canción. Actualmente, la asignación de características musicales depende del acceso a interfaces de programación de aplicaciones (API) de terceros, lo que genera restricciones de disponibilidad y costos. Esto afecta la escalabilidad y autonomía del sistema, y en consecuencia, la calidad de la experiencia ofrecida a los clientes.

Se propone el desarrollo de un sistema de inteligencia artificial (IA) que reciba como entrada canciones y genere como salida sus características musicales. Se entrenarán y evaluarán modelos de aprendizaje supervisado, a partir de técnicas y representaciones numéricas del sonido, fuentes de datos privadas de la empresa, y datos públicos disponibles. Y se podrán inferir las características de nuevas canciones sin depender de proveedores externos.

En el ámbito de la inteligencia artificial aplicada a la música, existen herramientas que permiten extraer información musical a bajo nivel, y herramientas en línea que permiten extraer algunas características específicas. Sin embargo, no se cuenta con una solución que provea resultados completos y resuelva el problema de la disponibilidad.

La propuesta de valor radica en otorgar a Plusyc Live SAS una solución completa, integrada y altamente disponible, en pro de la escalabilidad y la independencia tecnológica. Los comercios tendrán una renovación en la experiencia de sus consumidores. El sistema será además reutilizable en otros proyectos de la empresa.

A continuación, en la figura 1, se presenta el diagrama de bloques de alto nivel de la aplicación. A la derecha del diagrama se observa el sistema basado en IA, que es el foco del proyecto.

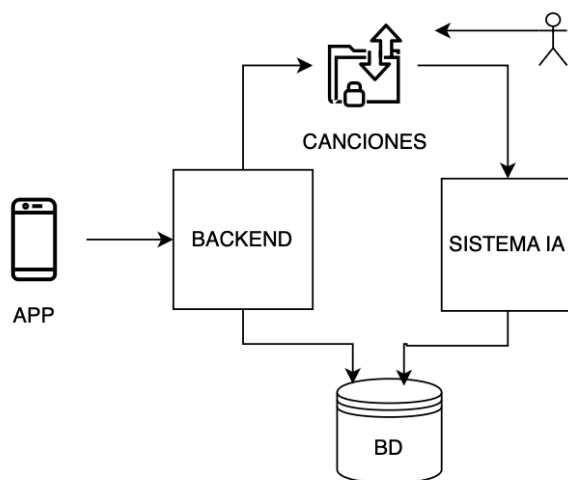


Figura 1. Diagrama en bloques del sistema.

En la figura se puede observar un actor que provee los archivos de las canciones que son las entradas del sistema IA, donde se procesa cada canción para extraer sus características musicales. Las características son las salidas, y son almacenadas en una base de datos que alimenta el *backend* de la aplicación. Ahora, en la figura 2, se muestra un diagrama de bloques más detallado del sistema IA.

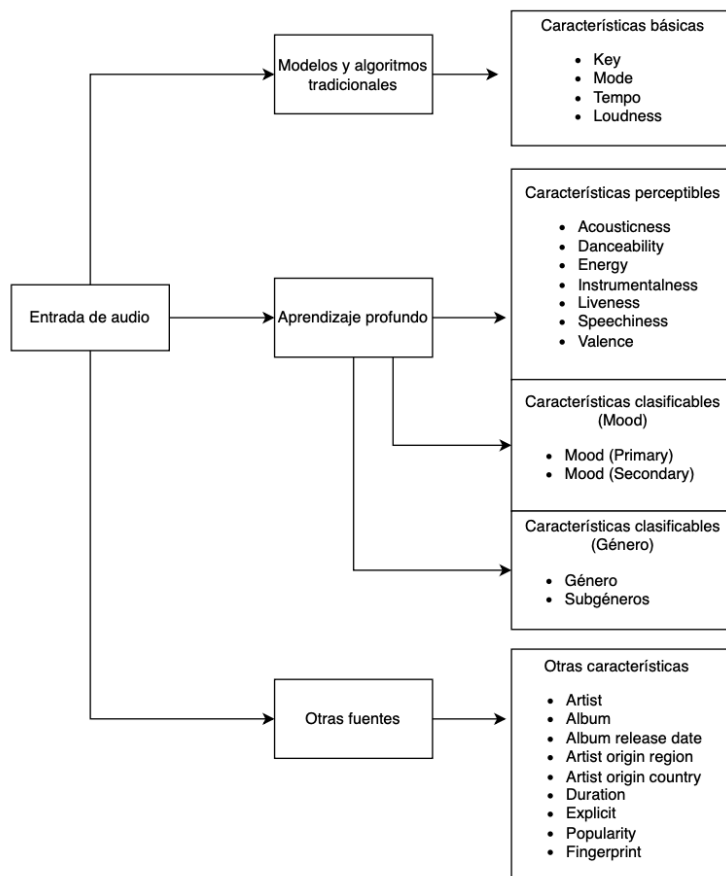


Figura 2. Diagrama de bloques del sistema IA.

En la figura se observa que el sistema IA utiliza tres módulos principales: “Modelos y algoritmos tradicionales”, “Aprendizaje profundo” y “Otras fuentes”. Cada módulo procesa el archivo de audio y se encarga de inferir o consultar un subconjunto específico de características musicales.

2. Identificación y análisis de los interesados

- Cliente: Carolina Arbelaez, es la encargada de aprobar los entregables.
- Impulsor: el Ing. Andrés Saldarriaga, es el responsable de brindar acceso a los datos del cliente, y las herramientas tecnológicas necesarias en producción, como credenciales, y proveedores de infraestructura en la nube.
- Responsable: Ing. Carlos Alberto Rivas Araque, es quien llevará a cabo el desarrollo del proyecto.

- Orientador: Ing. Esp. Martín Moreyra, es experto en solución de problemas de inteligencia artificial y va a ser consultor y ayuda para resolver problemas puntuales en caso de *blockers* técnicos.
- Usuario final: el usuario final son los clientes de Plusyc Live SAS, que utilizan la aplicación para ambientar su comercio con listas personalizadas.

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Carolina Arbelaez	Plusyc Live SAS	C.E.O.
Impulsor	Ing. Andrés Saldarriaga	Plusyc Live SAS	C.T.O.
Responsable	Ing. Carlos Alberto Rivas Araque	FIUBA	Alumno
Orientador	Ing. Esp. Martín Moreyra	GatekeeperX	Director del Trabajo Final
Usuario final	-	-	Locales comerciales

3. Propósito del proyecto

Desarrollar un sistema de inteligencia artificial capaz de caracterizar automáticamente canciones a partir de su archivo de audio, con el fin de reducir la dependencia de servicios externos y garantizar la escalabilidad, autonomía y confiabilidad de la aplicación de Plusyc Live SAS. Con ello, se busca fortalecer la experiencia musical personalizada que la empresa ofrece a los comercios y abrir la posibilidad de aplicar esta tecnología en otros contextos dentro del sector musical.

4. Alcance del proyecto

Se definen los siguientes subconjuntos de características musicales:

- Básicas: {*Key, Mode, Tempo, Loudness*}.
- Perceptibles: {*Danceability, Energy, Speechiness, Acousticness, Instrumentalness, Liveness, Valence*}.
- Clasificables por ánimo (*Mood*): {*Primary Mood, Secondary Mood*}.
- Clasificables por género: {*Genre, Subgenres*}.
- Otras (Aquellas que no requieren de IA para su asignación): {*Artist, Album, Album release date, Artist origin region, Artist origin country, Duration, Explicit, Popularity, Fingerprint*}.

El proyecto incluye la asignación de las características básicas, perceptibles y las clasificables por ánimo y género. Para lograr esto es necesario:

- Revisión del estado del arte sobre *datasets* musicales disponibles para modelos de aprendizaje supervisado (algoritmos tradicionales) y aprendizaje profundo.

- Evaluación de los datos del cliente para verificar volumen, calidad de asignaciones y posibilidad de conformar un *dataset* propio.
- Análisis de audio, representaciones numéricas de señales de audio para depurar los *datasets*.
 - Extracción de representaciones tradicionales para los modelos supervisados.
 - Generación de representaciones intermedias para aprendizaje profundo.
- Depuración de los *datasets* para los modelos de aprendizaje supervisado tradicionales.
- Elección de modelos de aprendizaje supervisado y algoritmos tradicionales para la predicción de las características básicas.
- Evaluación de los *datasets* para modelos de aprendizaje profundo.
- Selección de modelos de aprendizaje profundo y modelos preentrenados para la inferencia de características perceptibles, y clasificables por ánimo y género.
- Implementación de los modelos seleccionados.
- Construcción de un *pipeline* para la asignación de características mediante el uso de los modelos seleccionados como los mejores.
- Almacenamiento de las características de salida en la base de datos.

El presente proyecto no incluye:

- Asignación del subconjunto de otras características que no requieren de IA para su asignación.
- Desarrollo de una interfaz para la recepción de un nuevo archivo de audio.
- Desarrollo de interfaces gráficas de usuario.
- Puesta en producción del sistema en un entorno del cliente.
- Mantenimiento y monitoreo a largo plazo.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone:

- Disponibilidad de recursos de *hardware*: se dispondría de acceso a instancias de procesamiento locales, y en la nube con los suficientes recursos para las fases de entrenamiento y validación de los modelos.
- Disponibilidad de datos para el entrenamiento del modelo de procesamiento de audio: se tendría acceso a un conjunto diverso de datos de audio que cubrirán una amplia gama de géneros y estilos.
- Factibilidad técnica: se asume que las tecnologías actuales de procesamiento de audio son lo suficientemente avanzadas para implementar el proyecto. Y en particular.

- Las características básicas se pueden generar usando modelos de aprendizaje de máquina y algoritmos tradicionales.
- Las perceptibles y las clasificables por ánimo y género se pueden predecir usando un modelos de aprendizaje profundo de múltiples salidas.
- Tiempo: se estima que las 600 horas asignadas para el desarrollo del proyecto serán suficientes para completar todas las etapas, incluyendo la planeación, análisis y diseño, desarrollo, pruebas y potenciales correcciones del sistema.
- Asistencia de los interesados: se contaría con la ayuda del cliente ante *blockers* técnicos, y dudas sobre los requisitos del sistema.

6. Product Backlog

Se definen los siguientes roles:

- Usuario: la persona del lado del cliente con conocimientos en características musicales, para verificar que las salidas son correctas.
- Desarrollador de software con conocimiento en inteligencia artificial: la persona ocupando este rol deberá tener conocimiento suficiente en procesamiento de audio, y entrenamiento de modelos de inteligencia artificial, para la generación de características musicales.
- Cliente: es el encargado de verificar que el proyecto cumple con las especificaciones, y dar la aprobación final del sistema.

Épicas, historias de usuario (HU) y *spikes*.

- Selección de *datasets* y técnicas de representación de audio
 - **Spike 1 (3 story points (SP), prioridad máxima):** Como desarrollador de IA, quiero encontrar *datasets* musicales públicos, y técnicas de representación de audio para ser usados en algoritmos y modelos tradicionales.
 - **Spike 2 (2 SP, prioridad máxima):** Como desarrollador de IA, quiero determinar cuales *datasets* musicales públicos, y técnicas de representación de audio, se usarán para aprendizaje profundo.
 - **Spike 3 (3 SP, prioridad alta):** Como desarrollador de IA, quiero evaluar los datos del cliente, en términos de volumen y calidad, para determinar si es posible conformar un *dataset* propio.
- Desarrollo de algoritmos y modelos tradicionales para características básicas
 - **HU 1 (5 SP, prioridad alta):** Como desarrollador de IA, quiero realizar un análisis exploratorio de datos (EDA) de las característica básicas, para entender su distribución.
 - **HU 2 (5 SP, prioridad alta):** Como desarrollador de IA, quiero preparar los datos para que sean aptos para el modelado.
 - **HU 3 (5 SP, prioridad alta):** Como desarrollador de IA, quiero entrenar modelos tradicionales para predecir cada una de las características básicas.

- **HU 4 (5 SP, prioridad alta):** Como desarrollador de IA, quiero evaluar los resultados del modelo con métricas apropiadas, para validar su calidad, y seleccionar el mejor.
- **Desarrollo de modelos de aprendizaje profundo para características perceptibles**
 - **HU 5 (5 SP, prioridad alta):** Como desarrollador de IA, quiero realizar un EDA de los datos de las características perceptibles, para entender su distribución y correlaciones.
 - **HU 6 (5 SP, prioridad alta):** Como desarrollador de IA, quiero preparar los datos de audio para entrenar un modelo.
 - **HU 7 (5 SP, prioridad alta):** Como desarrollador de IA, quiero entrenar un modelo multi-salida de aprendizaje profundo para predecir las características perceptibles.
 - **HU 8 (5 SP, prioridad alta):** Como desarrollador de IA, quiero evaluar los resultados del modelo con métricas apropiadas para validar su desempeño.
- **Desarrollo de modelos de aprendizaje profundo para características clasificables por ánimo**
 - **HU 9 (3 SP, prioridad alta):** Como desarrollador de IA, quiero realizar un EDA de los datos de las características clasificables por ánimo, para analizar su distribución y categorías.
 - **HU 10 (3 SP, prioridad alta):** Como desarrollador de IA, quiero preparar los datos para el modelado de *moods*.
 - **HU 11 (3 SP, prioridad alta):** Como desarrollador de IA, quiero entrenar un modelo multi-salida de aprendizaje profundo para predecir *primary* y *secondary mood*.
 - **HU 12 (3 SP, prioridad alta):** Como desarrollador de IA, quiero evaluar el modelo con métricas de clasificación multi-clase para validar su desempeño.
- **Desarrollo de modelos de aprendizaje profundo para características clasificables por género**
 - **HU 13 (3 SP, prioridad alta):** Como desarrollador de IA, quiero realizar un EDA de los datos de géneros y subgéneros para entender su distribución y categorías.
 - **HU 14 (3 SP, prioridad alta):** Como desarrollador de IA, quiero preparar los datos para modelado de género.
 - **HU 15 (3 SP, prioridad alta):** Como desarrollador de IA, quiero entrenar un modelo multi-salida de aprendizaje profundo para predecir el género y los subgéneros.
 - **HU 16 (3 SP, prioridad alta):** Como desarrollador de IA, quiero evaluar los resultados del modelo con métricas de clasificación, para validar su desempeño.
- **Implementación del *pipeline* de procesamiento**
 - **HU 17 Opcional (8 SP, prioridad baja):** Como cliente, quiero una interfaz para la recepción de un nuevo archivo de audio, para alimentar el *pipeline* que genere las características musicales.
 - **HU 18 (8 SP, prioridad media):** Como cliente, quiero un *pipeline* que procese los modelos desarrollados para automatizar la generación de características musicales, y almacenar los resultados en una base de datos.

- **HU 19 Opcional (13 SP, prioridad baja):** Como cliente, quiero desplegar el sistema en el *backend*, para automatizar la generación de características musicales del audio en producción.
- **HU 20 (1 SP, prioridad alta):** Como usuario, quiero tener acceso de lectura a la base de datos para validar la calidad de las características resultantes.

7. Criterios de aceptación de historias de usuario

■ Selección de *datasets* y técnicas de representación de audio

• Spike 1

- Se genera un documento que incluye los hallazgos de *datasets* públicos, con ventajas y desventajas.
- Se listan y detallan las representaciones de audio disponibles.
- Se dispone de criterios de uso de los *datasets* y representaciones de audio para el conjunto de características básicas.

• Spike 2

- Se extiende el documento anterior con otros *datasets* específicos en el marco del aprendizaje profundo.
- Se agregan las representaciones de audio disponibles en este marco.
- Se añaden los criterios de uso de los *datasets* y representaciones de audio para los conjuntos de características perceptibles y de clasificación.

• Spike 3

- Se incluye un resumen del inventario de datos privados del cliente, audios y características.
- Se describe la calidad de los datos en términos de la consistencia de las características asignadas.
- Se describen las razones que determinan la viabilidad de construir y usar un *dataset* propio.

■ Desarrollo de algoritmos y modelos tradicionales para características básicas, perceptibles y clasificables por ánimo y género

• HU 1, HU 5, HU 9 y HU 13

- Se presenta un análisis exploratorio de datos con estadísticas descriptivas.
- Se identifican las distribuciones y correlaciones de los datos según gráficos y visualizaciones.
- El informe muestra el tratamiento de valores nulos o atípicos.
- Se describen las categorías del problema de clasificación: Aplica en HU 9, HU 13, y para *Key* y *Mode* en HU 1.

• HU 2, HU 6, HU 10 y HU 14

- Se realiza la normalización o estandarización de datos numéricos según aplique.
- Se codifican variables categóricas con técnicas estándar (p. ej., *one-hot encoding*) según aplique.
- Se documentan los pasos de limpieza de datos y el tratamiento de valores faltantes.

• HU 3, HU 7, HU 11 y HU 15

- En HU 3 se implementa al menos un modelo tradicional de aprendizaje supervisado, como máquinas de vectores de soporte (SVM), árboles aleatorios (RF), o k vecinos cercanos (kNN).
- Se ejecutan algoritmos tradicionales (sin IA) para comparar los resultados con los resultados del modelo tradicional. Aplica en el caso de HU 3.
- En HU 7, HU 11 y HU 15, se implementa al menos un modelo de red neuronal.
- Se documenta el proceso de selección de hiperparámetros, pruebas y resultados preliminares.
- **HU 4, HU 8, HU 12 y HU 16**
 - Se aplican métricas de desempeño (p. ej., *accuracy*, *F1*, *RMSE* según el caso).
 - Se selecciona el mejor modelo o algoritmo por característica en función de estas métricas.
 - Se entrega reporte comparativo de modelos y algoritmos.
- **Implementación del *pipeline* de procesamiento**
 - **HU 17 - opcional**
 - La interfaz permite subir archivos de audio en formato estándar (.mp3 o .wav).
 - Cada archivo se agrega a la cola de procesamiento.
 - El sistema devuelve confirmación de recepción.
 - **HU 18**
 - El *pipeline* procesa automáticamente un archivo nuevo.
 - Se ejecutan los modelos desarrollados.
 - Los resultados se almacenan en la base de datos.
 - El sistema almacena estado y detalle asociado al archivo.
 - **HU 19 - opcional**
 - El sistema está disponible en un entorno de producción del cliente.
 - El *backend* permite ejecutar al menos 10 archivos consecutivos sin fallo.
 - La documentación de despliegue está disponible para reproducir la instalación.
 - **HU 20**
 - El usuario accede a la base de datos en modo lectura.
 - El usuario puede filtrar los resultados por canción.
 - El usuario puede validar y reportar cualquier incidente al cliente y al desarrollador.

8. Fases de CRISP-DM

1. Comprensión del negocio:

Objetivo: minimizar dependencias de APIs externas mediante un módulo de IA propio que genere características musicales automáticamente.

Impacto: reducción de costos, autonomía tecnológica y optimización del flujo de ingestión de canciones.

Métricas: cobertura de características musicales, reducción de tiempo de respuesta en el *pipeline* y satisfacción del cliente.

2. Comprensión de los datos: Tipos de datos: archivos de audio y características musicales tabulares.

Fuentes de datos: datos privados del cliente y *datasets* públicos (p. ej., *GTZAN*, *Million Song Dataset*).

Cantidad de datos: aproximadamente 65,000 canciones con características asignadas, más la información pública disponible.

Calidad de los datos: datos revisados por músicos, sujetos a EDA.

3. Preparación de los datos:

Transformaciones necesarias: se transforman los audios en representaciones numéricas como *MFCC*. Normalización, segmentación de señales, y construcción de *datasets* balanceados.

Características clave: *chroma features* para características básicas, y espectrogramas para perceptibles y clasificables.

4. Modelado:

Tipo de problema: clasificación y regresión para características básicas, regresión para características perceptibles y clasificación multi-clase para características clasificables por ánimo y género.

Arquitecturas posibles:

- Modelos tradicionales para características básicas (SVM, RF, kNN).
- Algoritmos de procesamiento de señales (DSP) para características básicas.
- Modelos de aprendizaje profundo como redes neuronales convolucionales (CNN), redes neuronales recurrentes (RNN), *Transformers* y modelos preentrenados, para las características perceptibles, ánimo y género.

Se ejecuta un ciclo iterativo de experimentación con validación cruzada, comparación de arquitecturas y ajuste de hiperparámetros.

5. Evaluación del modelo:

Métricas de evaluación: *F1-score*, *AUC-ROC* para evaluar la capacidad del modelo de clasificación de características. *RMSE* y *MAE* para regresión.

6. Despliegue del modelo (opcional):

No se contempla como parte del alcance.

9. Desglose del trabajo en tareas

HU	Tarea técnica	Estimación	Prioridad
HU1	Generar visualizaciones de las distribuciones para características básicas	5 h	Alta
HU1	Identificar patrones, anomalías y faltantes para las características básicas	6 h	Alta
HU2	Implementar normalización y estandarización de variables numéricas	6 h	Alta
HU2	Codificar variables categóricas (ej., <i>one-hot encoding</i>)	5 h	Media
HU3	Implementar modelo <i>SVM</i> para predicción de características básicas	7 h	Alta
HU3	Entrenar y comparar <i>RF</i> y <i>kNN</i> como modelos alternativos	6 h	Media
HU4	Calcular métricas de desempeño (<i>accuracy</i> , <i>F1</i> , <i>RMSE</i>)	5 h	Alta
HU4	Elaborar reporte comparativo de modelos y algoritmos	4 h	Media
HU5	Aplicar técnicas de visualización e interpretar los resultados obtenidos para características perceptibles	5 h	Alta
HU5	Identificar patrones generales, anomalías, faltantes y correlaciones para las características perceptibles	6 h	Alta
HU6	Generar espectrogramas y normalizar audios	7 h	Alta
HU6	Implementar <i>data augmentation</i> para ampliar <i>dataset</i>	6 h	Media
HU7	Definir arquitectura de red neuronal multi-salida	8 h	Alta
HU7	Entrenar modelo inicial y guardar pesos	7 h	Alta
HU8	Evaluar desempeño del modelo con métricas apropiadas	5 h	Alta
HU8	Documentar resultados de evaluación y ajustes realizados	4 h	Media
HU9	EDA de distribución de <i>moods</i> (categorías principales/secundarias)	5 h	Alta
HU9	Generar gráficos de dispersión y matrices de correlación	4 h	Media
HU10	Preparar <i>dataset</i> de entrenamiento para clasificación de <i>moods</i>	6 h	Alta
HU10	Codificar etiquetas multi-clase y balancear <i>dataset</i>	5 h	Alta
HU11	Diseñar y entrenar red neuronal para predicción de <i>moods</i>	8 h	Alta
HU11	Ajustar hiperparámetros iniciales (tasa de aprendizaje, épocas)	6 h	Media
HU12	Evaluar el modelo con métricas multi-clase (<i>F1</i>)	5 h	Alta
HU12	Elaborar informe comparativo de experimentos realizados	4 h	Media
HU13	EDA de distribución de géneros y subgéneros musicales	5 h	Alta
HU13	Generar reportes visuales de categorías de género	4 h	Media
HU14	Preparar <i>dataset</i> para clasificación de género y subgénero	6 h	Alta
HU14	Aplicar técnicas de balanceo para clases poco representadas	5 h	Alta
HU15	Diseñar y entrenar red neuronal multi-salida para géneros	8 h	Alta
HU15	Comparar desempeño de diferentes arquitecturas (<i>CNN</i> , <i>RNN</i>)	7 h	Media
HU16	Evaluar métricas de desempeño en clasificación multi-clase	5 h	Alta
HU16	Documentar resultados y selección del mejor modelo	4 h	Media

HU	Tarea técnica	Estimación	Prioridad
HU18	Diseñar e implementar <i>pipeline</i> que integre modelos desarrollados	8 h	Alta
HU18	Configurar base de datos para almacenamiento automático de resultados	6 h	Alta
HU20	Crear consultas de solo lectura para validación de resultados	5 h	Alta
HU20	Implementar filtros de búsqueda por canción en la base de datos	6 h	Media

10. Planificación de Sprints

Recomendaciones:

- Verificar que la carga horaria por sprint sea equilibrada.
- Usar sprints de 1 a 3 semanas, acordes al cronograma general.
- Actualizar el % completado durante el seguimiento del proyecto.
- Considerar un sprint final exclusivo para pruebas, revisión y ajustes antes de la defensa.

Cuadro 1. Formato sugerido

Sprint	HU o fase	Tarea	Horas / SP	Responsable	% Completado
Sprint 0	Planificación	Definir alcance, cronograma y backlog inicial	15 h	Alumno	100 %
Sprint 0	Planificación	Reuniones iniciales con tutor/cliente	10 h	Alumno	50 %
Sprint 1	Spike 1 – 3	Selección de datasets y técnicas (EDA preliminar)	30 h	Alumno	0 %
Sprint 2	HU1 – HU2	EDA + preparación de datos (características básicas)	40 h	Alumno	0 %
Sprint 3	HU3 – HU4	Entrenamiento y evaluación de modelos tradicionales	45 h	Alumno	0 %
Sprint 4	HU5 – HU6	EDA y preparación de datos (perceptibles)	40 h	Alumno	0 %
Sprint 5	HU7 – HU8	Modelos profundos y métricas (perceptibles)	45 h	Alumno	0 %
Sprint 6	HU9 – HU10	EDA + preparación de datos (ánimo)	30 h	Alumno	0 %
Sprint 7	HU11 – HU12	Modelos profundos y métricas (ánimo)	35 h	Alumno	0 %
Sprint 8	HU13 – HU14	EDA + preparación de datos (género)	30 h	Alumno	0 %
Sprint 9	HU15 – HU16	Modelos profundos y métricas (género)	35 h	Alumno	0 %
Sprint 10	HU17 – HU20	Pipeline, BD y pruebas de integración	60 h	Alumno	0 %
Sprint 11	Escritura	Redacción memoria y documentación técnica	70 h	Alumno	0 %
Sprint 12	Defensa	Preparación de exposición y ajustes finales	45 h	Alumno	0 %

11. Diagrama de Gantt (sprints)

Visualizar en un diagrama de Gantt la planificación temporal del proyecto, tomando como base los sprints definidos en la sección anterior. Debe contemplar todas las horas del proyecto.

Consigna:

- Elaborar un diagrama de Gantt que muestre la secuencia temporal de los sprints.
- Cada fila debe representar un sprint (con su número o nombre), y el eje horizontal debe indicar el tiempo (en semanas o fechas concretas).
- Las tareas técnicas derivadas de HU deben diferenciarse visualmente (por ejemplo, con un color distinto) de las tareas no técnicas (planificación, redacción, defensa).
- Incluir todas las tareas estimadas en cada sprint.

Recomendaciones para el Gantt:

- Podés usar herramientas gratuitas como TeamGantt, ClickUp, GanttProject, [Google Sheets], [Trello + Planyway], entre otras.
- Ordená los sprints de forma cronológica, comenzando con Sprint 0 (planificación) y finalizando con el sprint de defensa.
- Asegurate de reflejar la duración realista de cada sprint según tu disponibilidad y el cronograma general del posgrado.
- Incluí hitos importantes: reuniones, entregas parciales, defensa.

Incluir una imagen legible del diagrama de Gantt. Si es muy ancho, presentar primero la tabla y luego el gráfico de barras.

12. Normativa y cumplimiento de datos (gobernanza)

En esta sección se debe analizar si los datos utilizados en el proyecto están sujetos a normativas de protección de datos y privacidad, y en qué condiciones se pueden emplear.

Aspectos a considerar:

- Evaluar si los datos están regulados por normativas como GDPR, Ley 25.326 de Protección de Datos Personales en Argentina, HIPAA u otras según jurisdicción y temática.
- Determinar si el uso de los datos requiere consentimiento explícito de los usuarios involucrados.
- Indicar si existen restricciones legales, técnicas o contractuales sobre el uso, compartición o publicación de los datos.

- Aclarar si los datos provienen de fuentes licenciadas, de acceso público o bajo algún tipo de autorización especial.
- Analizar la viabilidad del proyecto desde el punto de vista legal y ético, considerando la gobernanza de los datos.

Este análisis es clave para garantizar el cumplimiento normativo y evitar conflictos legales durante el desarrollo y publicación del proyecto.

13. Gestión de riesgos

a) Identificación de los riesgos (al menos cinco) y estimación de sus consecuencias:

Riesgo 1: detallar el riesgo (riesgo es algo que si ocurre altera los planes previstos de forma negativa)

- Severidad (S): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

Riesgo 3:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

b) Tabla de gestión de riesgos: (El RPN se calcula como $RPN=S \times O$)

Riesgo	S	O	RPN	S*	O*	RPN*

Criterio adoptado:

Se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a...

Nota: los valores marcados con (*) en la tabla corresponden luego de haber aplicado la mitigación.

c) Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido:

Riesgo 1: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).
Nueva asignación de S y O, con su respectiva justificación:

- Severidad (S*): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O*): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

Riesgo 3: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

14. Sprint Review

La revisión de sprint (*Sprint Review*) es una práctica fundamental en metodologías ágiles. Consiste en revisar y evaluar lo que se ha completado al finalizar un sprint. En esta instancia, se presentan los avances y se verifica si las funcionalidades cumplen con los criterios de aceptación establecidos. También se identifican entregables parciales y se consideran ajustes si es necesario.

Aunque el proyecto aún se encuentre en etapa de planificación, esta sección permite proyectar cómo se evaluarán las funcionalidades más importantes del backlog. Esta mirada anticipada favorece la planificación enfocada en valor y permite reflexionar sobre posibles obstáculos.

Objetivo: anticipar cómo se evaluará el avance del proyecto a medida que se desarrollen las funcionalidades, utilizando como base al menos cuatro historias de usuario del *Product Backlog*.

Seleccionar al menos 4 HU del Product Backlog. Para cada una, completar la siguiente tabla de revisión proyectada:

Formato sugerido:

HU seleccionada	Tareas asociadas	Entregable esperado	¿Cómo sabrás que está cumplida?	Observaciones o riesgos
HU1	Tarea 1	Módulo funcional	Cumple criterios de aceptación definidos	Falta validar con el tutor
	Tarea 2			
HU3	Tarea 1	Reporte generado	Exportación disponible y clara	Requiere datos reales
	Tarea 2			
HU5	Tarea 1	Panel de gestión	Roles diferenciados operativos	Riesgo en integración
	Tarea 2			
HU7	Tarea 1	Informe trimestral	PDF con gráficos y evolución	Puede faltar tiempo para ajustes
	Tarea 2			

15. Sprint Retrospective

La retrospectiva de sprint es una práctica orientada a la mejora continua. Al finalizar un sprint, el equipo (o el alumno, si trabaja de forma individual) reflexiona sobre lo que funcionó bien, lo que puede mejorarse y qué acciones concretas pueden implementarse para trabajar mejor en el futuro.

Durante la cursada se propuso el uso de la **Estrella de la Retrospectiva**, que organiza la reflexión en torno a cinco ejes:

- ¿Qué hacer más?
- ¿Qué hacer menos?
- ¿Qué mantener?
- ¿Qué empezar a hacer?
- ¿Qué dejar de hacer?

Aun en una etapa temprana, esta herramienta permite que el alumno planifique su forma de trabajar, identifique anticipadamente posibles dificultades y diseñe estrategias de organización personal.

Objetivo: reflexionar sobre las condiciones iniciales del proyecto, identificando fortalezas, posibles dificultades y estrategias de mejora, incluso antes del inicio del desarrollo.

Completar la siguiente tabla tomando como referencia los cinco ejes de la Estrella de la Retrospectiva (*Starfish* o estrella de mar). Esta instancia te ayudará a definir buenas prácticas desde el inicio y prepararte para enfrentar el trabajo de forma organizada y flexible. Se deberá completar la tabla al menos para 3 sprints técnicos y 1 no técnico.

Formato sugerido:

Sprint tipo y N°	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint técnico - 1	Validaciones continuas con el alumno	Cambios sin versión registrada	Pruebas con datos simulados	Documentar cambios propuestos	Ajustes sin análisis de impacto
Sprint técnico - 2	Verificar configuraciones en múltiples escenarios	Modificar parámetros sin guardar historial	Perfiles reutilizables	Usar logs para configuración	Repetir pruebas manuales innecesarias
Sprint técnico - 8	Comparar correlaciones con casos previos	Cambiar parámetros sin justificar	Revisión cruzada de métricas	Anotar configuraciones usadas	Trabajar sin respaldo de datos
Sprint no técnico - 12 (por ej.: “Defensa”)	Ensayos orales con feedback	Cambiar contenidos en la memoria	Material visual claro	Dividir la presentación por bloques	Agregar gráficos difíciles de explicar